

Сравнительный анализ библиотек NLTK и Natasha для обработки русскоязычных текстов.

Введение

В рамках данного исследования проведено сравнительное тестирование библиотек для обработки естественного языка (NLP): универсальной библиотеки NLTK и специализированной для русского языка библиотеки Natasha. Тестирование проводилось на идентичных текстах для обеспечения объективности сравнения и включало:

- Сегментация текста на предложения
- Токенизация на слова
- Обработка специальных случаев (сокращения, даты, ФИО, технические обозначения)

Для тестирования использовались программы `natali.py` и `nltk.py`, которые обрабатывали текст, используя функции библиотек, а затем выводили результат сегментации и токенизации.

Методология исследования

Тестовые данные

Для тестирования использовались специально разработанные тексты, содержащие сложные случаи русского языка:

Примеры для сегментации:

- Тексты с различными знаками препинания (многоточия, комбинированные знаки)
- Предложения с сокращениями и инициалами (т.е., А.С. Пушкин)
- Конструкции с прямой речью и кавычками
- Научные и технические тексты с датами, временем, специальными обозначениями

Примеры для токенизации:

- Буквенно-цифровые комбинации (СУ-35, А380, Р236РВ177)
- Даты и время в различных форматах (23.07.2025, 14:30)
- Дробные числа и проценты (75,5%, 3.5 м/с)
- Сложные сокращения (т.д., шт., рис.)

Критерии оценки

- Правильность разбиения на предложения
- Корректность выделения отдельных токенов
- Обработка специальных случаев русского языка

Результаты тестирования

Токенизация (разбивка на слова)

Сравнительная таблица результатов токенизации

Категория	Пример	Natasha	NLTK	Результат
Буквенно-цифровые комбинации	P236PB177	['P','236','PB','177']	['P236PB177']	NLTK корректно
Сокращения	т.д.	['т','.',',','д','.',',']	['т.д.']	NLTK корректно
Инициалы	А.С. Пушкин	['А.С','.',',','Пушкин']	['А.С','.',',','Пушкин']	Одинаково
Дефисные слова	черно-белый	['черно-белый']	['черно-белый']	Одинаково
Числа с единицами	3.5 м/с	['3.5','м','/',',','с']	['3.5','м/с']	NLTK лучше
Научная нотация	-87.21E-5	['-',',','87.21','Е-5,',']	['-87.21E-5']	NLTK корректно

Анализ результатов токенизации

NLTK продемонстрировал превосходство в обработке технических и сложных конструкций:

Корректная обработка буквенно-цифровых комбинаций:

Текст: "P236PB177, T12-B15"

Natasha: ['P','236','PB','177',',',',',', 'T','12-B','15']

NLTK: ['P236PB177', ',', 'T12-B15']

Правильное распознавание сокращений:

Текст: "и т.д., шт., рис."

Natasha: ['и', 'т', '.', 'д', '.', '.', 'шт', '.', '.', 'рис', '.']

NLTK: ['и', 'т.д.', ',', 'шт.', ',', 'рис', '.']

Natasha показала слабые результаты в технической токенизации, но хорошо справилась с обычными русскоязычными.

Сегментирование (разбивка на предложения)

Сравнительная таблица результатов сегментирования

Категория	Пример	Natasha	NLTK	Результат
Обычный текст	Научный отчет	6 предложений	12+ предложений	Natasha лучше
Прямая речь	Диалог с тире	7-9	10+	Natasha лучше

		предложений	предложений	
Сокращения	т.е., напр., см.	Не разбивает	Разбивает на каждом	Natasha лучше
Многоточия	Текст... продолжение	Цельное	Частичное разбиение	Natasha лучше

Анализ результатов сегментирования

Natasha показала значительно лучшие результаты в сегментации русскоязычных текстов:

Критические ошибки NLTK:

Текст: "Докладчик — проф. А.В. Семенов."

NLTK: ['Докладчик — проф.', 'А.В.', 'Семенов.'](3 предложения)

Natasha: ['Докладчик — проф. А.В. Семенов.'](1 предложение)

Текст: «Т.е. нам нужны правки?» — уточнила она.

NLTK: ['«Т.е.', 'нам нужны правки?» — уточнила она.'](2 предложения)

Natasha: ['«Т.е. нам нужны правки?» — уточнила она.'](1 предложение)

Проблемы Natasha с прямой речью:

Текст: «Иван Петрович, вы уже просмотрели договор? — спросила секретарша. — Клиент ждет ответа».

Natasha: ['«Иван Петрович, вы уже просмотрели договор?',

'— спросила секретарша.',

'— Клиент ждет ответа».'](3 предложения вместо 1)

Обсуждение результатов

Сильные стороны NLTK

Эффективная обработка технических конструкций - корректно распознает сложные буквенно-цифровые комбинации

Умная работа с числами и формулами - правильно обрабатывает научную нотацию, дроби, проценты

Универсальность - подходит для обработки текстов с технической и научной лексикой

Сильные стороны Natasha

Глубокое понимание русской морфологии - корректно обрабатывает сокращения, инициалы, падежи

Оптимизированная сегментация - правильно определяет границы предложений в русскоязычных текстах

Специализация на русском языке - учитывает специфику русской пунктуации и грамматики

Слабые стороны NLTK:

Некорректная обработка русских сокращений

Проблемы с сегментацией предложений с прямой речью

Непонимание специфики русской пунктуации

Слабые стороны Natasha:

Слабая обработка технических обозначений

Проблемы с сложными буквенно-цифровыми комбинациями

Ошибки в токенизации специализированной лексики

Заключение

Проведенное исследование демонстрирует, что выбор между NLTK и Natasha должен определяться характером обрабатываемых текстов.

NLTK показал лучшие результаты в обработке технических и научных текстов, корректно работая со сложными числовыми и буквенно-цифровыми конструкциями. Однако его возможности ограничены при работе с русскоязычными текстами, содержащими специфическую пунктуацию и морфологию.

Natasha, будучи специализированным решением для русского языка, демонстрирует превосходство в сегментации и обработке обычных текстов, но уступает в технической токенизации.

Оптимальным решением является комбинированный подход, учитывающий тип обрабатываемого текста и использующий сильные стороны каждой библиотеки в соответствующих областях.